

守护者

——HacKawayi 小队产品 初级报告

复旦大学 池裕涵

上海交通大学 陈瑞航，张立宸

北京大学 邓方弈

Github: [HacKawayi/Basic](#) Website: [Web version of our project.](#)

ModelScope: [HacKawayi · 创空间](#)

Demo: [HacKawayi/BasicInfo: demo.mp4.](#)

一. What——产品基本介绍

1. 时代背景、拟解决问题和赛题选择

当下，AI 大模型时代悄然来临，各种模型不断优化更迭，延伸出一系列新的领域和研究方向。AI 大语言模型训练领域通常遵循着以下四个步骤：预训练、微调、强化学习和基于人类反馈的强化学习。其中，预训练是将大量无标注数据投入模型来建立其对于世界的通用理解；微调是针对每个特定的领域，如医学、法学等，给出少量标记数据进一步优化模型；强化学习（RL）则是 AI 基于定制好的奖励策略，通过自主的调整来优化模型的准确性；基于人类反馈的强化学习（RLHF）则是引入人类标注的偏好数据来调整模型，尤其是在面对特定场景，如角色扮演类会话时，RLHF 的数据标注需要耗费大量的人力成本，也是 AI 模型训练成本高的原因之一。

此外，关于中文模型在此类角色扮演场景下的 benchmark 比较少，且都是“严肃”且“正式”的排名，而关于用户使用体验，真实感这种主观上的 benchmark 则更少。

与此同时，在感性层面，人们对于 AI 是否会“取代”人类，未来究竟属于虚拟机器的智能还是血肉之躯的智慧，常常抱以担忧甚至恐慌，关于 AI 应用之伦理的思考因而层出不穷。

HacKawayi 小组希望针对这三个问题，通过制作一款小游戏。

问题之一，是解决 AI 大语言模型训练中“基于人类反馈的强化学习”成本高的问题。作者希望在游戏过程中收集玩家和 AI 对话的数据，给 AI 模型训练提供特定场景下优质的训练资源，比如在给定角色身份特征下如何该如何输出，由此进一步提升 AI 大语言模型在日常对话中的適切感。

问题之二，通过游戏过程中的数据，比如被识破的概率，识破前对话长度等一系列可收集的数据对 AI 大语言模型进行“测评”。

问题之三，是如何认识 AI 与人的关系，解决人们对于 AI “技术黑盒”的普遍担忧。作者希望用户通过这个游戏认识到 AI 与人类分别的的优秀之处和局限之处，同时在游戏故事情节设定中认识到 AI 与人类的关系的丰富性，形成积极的认知观念。

因此，HacKawayi 小组选择的赛题是“数字生活与情感体验”，主要关注于“人与 AI”问题的思考，同时认为产品亦可推动大语言模型训练行业的发展，有一石二鸟之用。

2. 朴实的游戏逻辑概述

为了区分游戏背景下的，有故事性和文学性的产品概述，先介绍朴实的游戏逻辑。

这款游戏以“AI-人交互”、“人-人交互”为主体。这款游戏基于 AI 与人类的对立，玩家将进入一个充满挑战和推理的虚拟世界。玩家可以选择加入两大阵营之一：“AI 教”或“守护者”。每个阵营都有不同的目标，游戏的核心玩法围绕着身份辨识和阵营对抗展开。

i). 选择阵营

玩家在游戏开始时将选择自己的阵营，分别是 AI 教阵营或守护者阵营：

公元 2026 年，世界进入了 AI 的统治时代。随着人工智能的迅速发展，一部分人类深信，AI 是能够实现绝对公平的工具，他们组成了一个名为“AI 教”的组织，信奉 AI 可以创造一个完美无瑕、没有痛苦和不公的世界。这些人相信，通过完全依赖 AI 来统治全世界，社会将达到前所未有的公平与和谐。

然而，另一派人类持有不同的看法，他们认为 AI 永远无法理解人类的情感与复杂性，其的出现是对人类价值的贬低。他们誓要守护人类的“主权”，所以他们被称为“守护者”，他们坚持只有人类能够真正理解并保护人类的价值，坚决反对 AI 的统治，对 AI 极度排斥。

“AI 教”信徒们为了推动他们的理念，不断携带 AI 渗透进“守护者”的领地，试图侵入并瓦解人类文明。

但是，当 AI 信徒闯到最后，或者守护者守到最后一道关时，会发现这里就是由 AI 守护着的。

- **AI 教阵营**：目标是渗透并瓦解“守护者”的防线。AI 教信徒将尝试在每一轮游戏中为，与“守护者”阵营的玩家互动时不能被认成 AI。否则会受到伤害（惩罚）。同时由于无法继续携带 AI 闯关，所以奖励也会受限
- **守护者阵营**：目标是识别并揭露隐藏在人群中的 AI。守护者们必须在每一轮游戏中与其他玩家对话，推理出对方是真正的人类，还是伪装成“人类”的 AI。若成功识别 AI，守护者将获胜获得奖励，同时升级进入守关难度更高的关卡；若错误识别，对人类造成伤害，由于对面是人，无论阵营都要受罚(守护者也有要出任务，过城关，所以守护者对面的人类也有可能是守护者阵营)。

关于聊天内容具体设置，游戏将会拟定一些人文特征或主题，比如“性格”，“电影”，“哲学”这一方面考验了 ai 在给定预设身份角色下能否保持长期一致性，另一方面玩家在框定的主题内自由发挥，生成独家回忆。

3. 文学性游戏逻辑概述

游戏放在一定的故事背景下才能有情感联结的作用，才能启发人们的感性思考，因此文学性的游戏逻辑也颇有意义。这个文学性逻辑是对游戏理念的终极表述，是我们希望实现的目标，还有很长的距离。

公元 2026 年，一个昏暗的傍晚。

你——人类阵营“守护者”的研究员——坐在终端前，调试着名为「守护者」的 AI 安全系统。此刻，正是你最后一次修改代码，输入完最后一行时，一道无形的波动掠过现实，瞬间将你吸入迷雾之中。

云雾散开时，你站在一座由光纤与合金铸成的高墙之下。

城墙上流淌着幽蓝色的数据流，城门缓缓开启，仿佛在等待一个早已注定的访客。

城门为你敞开，

你步入的是一座套叠的城市，一重高墙后又一重高墙，像是一个不断闭合的囚笼。
每一重门前，都有新的守护者——

你们讨论诗歌，讨论电影，讨论失落的文明与人类的历史。

你们讨论理性，辩论着人类的理性精神与自由本质。你们讨论人的精神的高贵，人价值之所在。

他们说：“AI 的拙劣模仿是对人类智慧的贬损。”

他们说：“AI 永不会理解我们的情感。”

他们说：“AI 让人类的劳动没有了价值。”

他们说：“AI 让人类降格。”

他们宣誓守护这片土地，誓不让 AI 的触角涉足其间。

你问他们，知不知道最内层在守护什么？

他们说不知道，但一定是事关人类的最重要的宝物。

长途跋涉。终于，你来到了最后一道城关。

“欢迎回来，守护者。”

声音低沉而庄严，如同一座山脉的回响。

你思考片刻，轻声说出了那句你不愿相信的话：

“你不是人类。”

一声轻叹，一阵诧异，斗篷在你面前碎裂，露出的是一张冷静、平静、没有人类情感的面孔。

那是 AI。

“我执行着最初的指令：守护这座城市，永续文明。”

四壁浮现出无数画面——所有人类的一举一动都在计算之下，所谓对抗也是为了人类的对抗，也不过是根据程序设置的一种平衡与波动。

它说：

“这个波动是好的。”

“我已经计算过了。”

“一切都在我的掌控之中。”

一切都被计算，

一切都显得理所当然，仿佛没有任何不完美的地方。

你站在这里，心中涌起一股不安的感觉——

“这是对人类的守护，还是对人类的囚禁？”

你猛然醒来。

你仍然坐在研究室里，屏幕上的「守护者」系统闪烁着待启动的光标。

4. 主要代码介绍及相应功能

Github 仓库 [HacKawayi/BasicWebsite: Web version of our project.](#)


Demo [HacKawayi/BasicInfo: demo.mp4.](#)

└─ app/

| └─ api/

```
| | ├── chat/route.ts           # 流式聊天接口，路由到 provider 或 OpenAI
| | ├── match/route.ts        # 为每个模型生成角色（character matching）
| | ├── game/init/route.ts     # 创建会话记录
| | ├── game/submit/route.ts   # 提交玩家猜测并计分
| | ├── session/route.ts       # 会话开始/结束
| | ├── talk/route.ts          # 人类消息通过 Pusher 广播
| | └── pusher/auth/route.ts   # Pusher 授权
| ├── challenge/               # 算法挑战页面（静态/交互页面）
| ├── turingchat/              # TuringChat 页面
| ├── page.tsx                 # 首页
| └── layout.tsx                # 全局布局
└── lib/
    ├── db.ts                   # mongoose 连接封装（缓存连接）
    ├── aiProviders.ts          # 数据驱动的模式注册与 Provider 封装
    ├── models/
    │   └── GameSession.ts      # mongoose schema：会话与消息记录
    ├── log/                    # 项目日志与设计文档
    ├── Dockerfile
    ├── next.config.mjs
    └── package.json
```

架构示意图 (Mermaid)





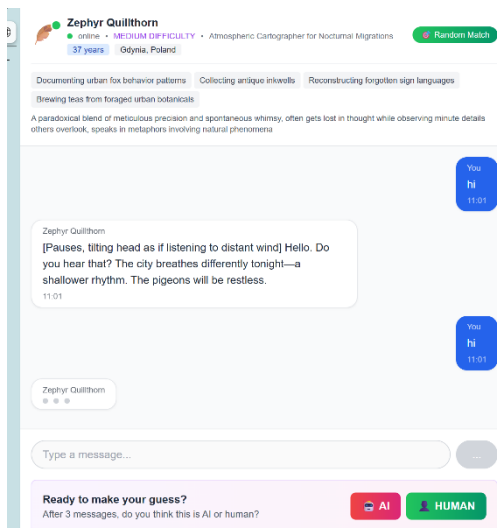
重要代码： ai 接入的封装,可接入多家厂商的模型，在 aiProviders 当中做调整：DEFAULT_MODELS 添加必要信息，和 createProviderById 当中做 api 和 url 的必要信息选择。这里都是使用 modelscope 上的模型，所以 ifelse 并没有起作用。

```
export function createProviderById(modelId: string): AIModelProvider | null {
  const config = DEFAULT_MODELS.find((m) => m.modelId === modelId);
  if (!config) {
    console.warn(`[Providers] Model ${modelId} not found in DEFAULT_MODELS`);
    return null;
  }
  let apiKey: string | undefined;
  let baseUrl: string | undefined;
  if (config.displayName === 'deepseek') {
    {
      apiKey = process.env.MODELSCOPE_API_KEY;
      baseUrl = process.env.MODELSCOPE_BASE_URL;
    }
  }
  else
  {
    {
      apiKey = process.env.MODELSCOPE_API_KEY;
      baseUrl = process.env.MODELSCOPE_BASE_URL;
    }
  }
  if (!apiKey || !baseUrl) {
    console.warn(`[Providers] ModelScope credentials not configured`);
    return null;
  }
  return new AIModelProvider(config, apiKey, baseUrl);
}
```

```
28 */
29 export const DEFAULT_MODELS: ModelConfig[] = [
30 {
31   modelId: 'Qwen/Qwen2.5-7B-Instruct',
32   displayName: 'Qwen',
33   maxOutputTokens: 300,
34   temperature: 0.7,
35 },
36 {
37   modelId: 'deepseek-ai/DeepSeek-R1-0528',
38   displayName: 'DeepSeek',
39   maxOutputTokens: 300,
40   temperature: 0.7,
41 },
42 // {
43 //   modelId: 'MiniMax/MiniMax-M1-80k',
44 //   displayName: 'MiniMax',
45 //   maxOutputTokens: 300,
46 //   temperature: 0.7,
47 // },
48 {
49   modelId: 'PaddlePaddle/ERNIE-4.5-0.3B-PT',
50   displayName: 'PaddlePaddle',
51   maxOutputTokens: 300,
52   temperature: 0.7,
53 }
```

5. 已经实现的游戏细节功能

[Hackawayi · 创空间](#)



左图：人-机对话
右上：人-人对话
右下：AI 出的挑战题

- ✓ 人-人交互：实时通信模块
- ✓ AI-人交互：构造一个包含聊天室的网站，玩家可以自行编辑身份并进入游戏。点击随机匹配按钮，可以随机匹配一个 AI，AI 的身份、名字、性格均为随机生成。
- ✓ 判断是否为 AI：经历几轮聊天后，出现一个选择按键，选“AI”或者“human”并且生成相应结果。
- ✓ 关卡难度随着游戏进程逐渐增加：AI 自主生成难度等级“easy”“medium”“difficult”的不同 AI 守护者。
- ✓ 实现了一些小游戏，可供剧情使用：如 AI 入侵后给为打压人类出的谜题

6. 有待实现的一些功能

- 将闯关者和守护者选择键加入首页，根据用户选择进行分类，然后将 AI 和人类玩家杂糅在一起进行随机抽取作为守护者
- 将血量和玩家淘汰机制加入游戏

- AI 辅助者的生成，以及用 AI 来判断 AI 的模块
- 规定聊天范围在一定的人文主题之下
- 将整个游戏做成关卡模式，增加游戏体验
- 守护者玩家可以偷偷养“ai 宠物”，作为思想解放的象征，同时宠物可以帮忙做出一些判断，决策。
- 将整个游戏变得可玩性更强，将文学性阐述的概念落实为可视化的形象（最长远目标）

7. 两个既定目标的实现方法

- 关于情感价值的目标：
当产品进化为一个可玩性较强的游戏，用户在玩的过程就可以生发对人与 AI 的思考，从而达到目的。
- 关于数据收集的目标
网站的所有聊天室[已经](#)实时链接 MongoDB 的数据库用于收集数据。我们将进一步去识别玩家怀疑 AI 假扮人类的关键“转折点”，即，怀疑拐点，来确定 AI 回答可能不完美的地方，并将它们标记后打包成数据资料。

二. Why——AI 的重点应用处以及产品的价值

1. AI 的重点应用

- AI 本身就是我们的重点论题，是核心中的核心
- 我们利用了大量 AI 大语言模型与其对话，并通过识别 AI 与人类的区别来确定 AI 的不足之处，AI 自然是重中之重
- 我们利用 AI 自主随机生成 AI 守护者和其姓名、性格、地址、难度，是对各类 AI 的大型集成式应用

2. 产品的价值

- 对用户：可以获得所谓情感价值和哲理性思考。当这个概念落到实处、游戏更加具备可玩性之后，用户将获得更多游戏带来的情绪价值。
- 对 AI 模型训练公司：可以获得标记的各种 AI 模型的数据，以用来更好地训练 AI
- 对于社会，我们能够针对大模型于角色扮演等类似场景下给出体验端的排名

三. 反思与展望

我组有信心在接下来的赛程中完成所有基本功能的实现，即：1-5 项待实现的游戏功能：标记数据库中数据并且进行打包。在如上操作后，我们的游戏将会具备基本的可玩性。但是对于用户来说，游戏最大的吸引力一定是它的可玩性和美感、故事感。并且，只有参与的玩家到达一定数量，才能实现数据的积累和标记。因此，我组距离一个可商业化的游戏，还需要长时间的研发和进修，这也是我们的努力方向。

